Sáu câu hỏi nghiên cứu

RQ1

Association

Điểm nào liên quan mạnh nhất?

RQ2

Selection

Mô hình nào phù hợp nhất?

RQ3

Imbalance

SMOTE + F2 có giúp không?

RQ4

Consistency

Liên hệ có lặp lại qua cấu trúc?

RQ5

Robustness

Kết quả còn giữ khi grouped?

RQ6

Explainability

SMOTE và SHAP nói gì?

RQ1 — ASSESSMENT ASSOCIATION

Độ lớn tương quan |r| với TARGET = 1 (unsuccessful)



Tất cả r được báo cáo là âm: điểm cao hơn gắn với tỷ lệ unsuccessful thấp hơn.

Insight

Progress Tests-30 có |r| cao nhất nhưng chỉ n=165. Practical Exam có độ phủ lớn hơn nhiều. Vậy nên tương quan mạnh không đồng nghĩa với biến quan trọng nhất

Cách nói an toàn

“Strongest observed bivariate association” — không nói “most important predictor” và không suy diễn nhân quả.

RQ2 — So sánh các Model

Production validation



RF ROC-AUC

0.9488

best by F2, not AUC

LGBM ROC-AUC

0.9604

higher AUC

Decision

Random Forest được chọn dưới validation F2 vì nghiên cứu ưu tiên recall. LightGBM và XGBoost có ROC-AUC/PR-AUC cao hơn.

F2 ưu tiên recall hơn precision — đây là lý do tiêu chí chọn phải luôn đi kèm với từ “best”.

RQ3 — SMOTE production

Baseline và SMOTE sau threshold selection trên validation

Baseline F2

0.8524

threshold 0.40

SMOTE F2

0.8518

threshold 0.33

Baseline recall

0.8683

SMOTE recall

0.8682

Quy tắc thực nghiệm

SMOTE chỉ fit trên train; threshold chọn từ validation; test dành cho đánh giá cuối.

ΔF2 = −0.00060

SMOTE thay đổi điểm vận hành nhưng không chứng minh cải thiện hay suy giảm đáng kể. Test không được dùng để chọn ngưỡng.

-> SMOTE không tạo ra lợi ích đáng kể trong production

RQ4 — CROSS-STRUCTURE CONSISTENCY

Median |r|



Quy tắc đọc kết quả

PROJECT có median |r| lớn nhất nhưng chỉ 2 tệp. Với tiêu chí ≥5 tệp, Practical Exam là nhóm mạnh nhất được lặp lại tốt.

Insight: consistency = magnitude + replication, không chỉ là magnitude.

Không được diễn giải là causal effect; missing/structural absence không phải score = 0.

RQ5 — So sánh Grouped model

Grouped split theo (SOURCE_FILE, CODE)

Train
66,491

Validation
22,236

Test
21,977

Overlap
0
mọi cặp split

Validation F2



Kết luận

RF vẫn đứng đầu theo validation F2. Đây là robustness với split design, không phải bằng chứng cho unseen students/future cohorts.

RQ6 — GROUPED SMOTE DESIGN

Đây là thí nghiệm grouped mới, không phải bản sao của RQ3

RQ3 · Production/random

SMOTE comparison trên production split; kết quả chính: ΔF2 = −0.00060.

RQ6 · Grouped

SMOTE + SHAP trên split theo (SOURCE_FILE, CODE); threshold 0.35 vs 0.34.

Pipeline logic

TRAIN
median imputation
SMOTE chỉ tại đây

→

VALIDATION
chọn threshold
F2 là tiêu chí

→

TEST
đánh giá cuối
không tuning

RQ6 — Grouped peformance

Grouped test sau khi chọn threshold trên validation

Baseline F2

0.84080

threshold 0.35

SMOTE F2

0.84325

threshold 0.34

Precision

+0.04687

SMOTE – baseline

Recall

−0.01142

SMOTE – baseline

+0.00246

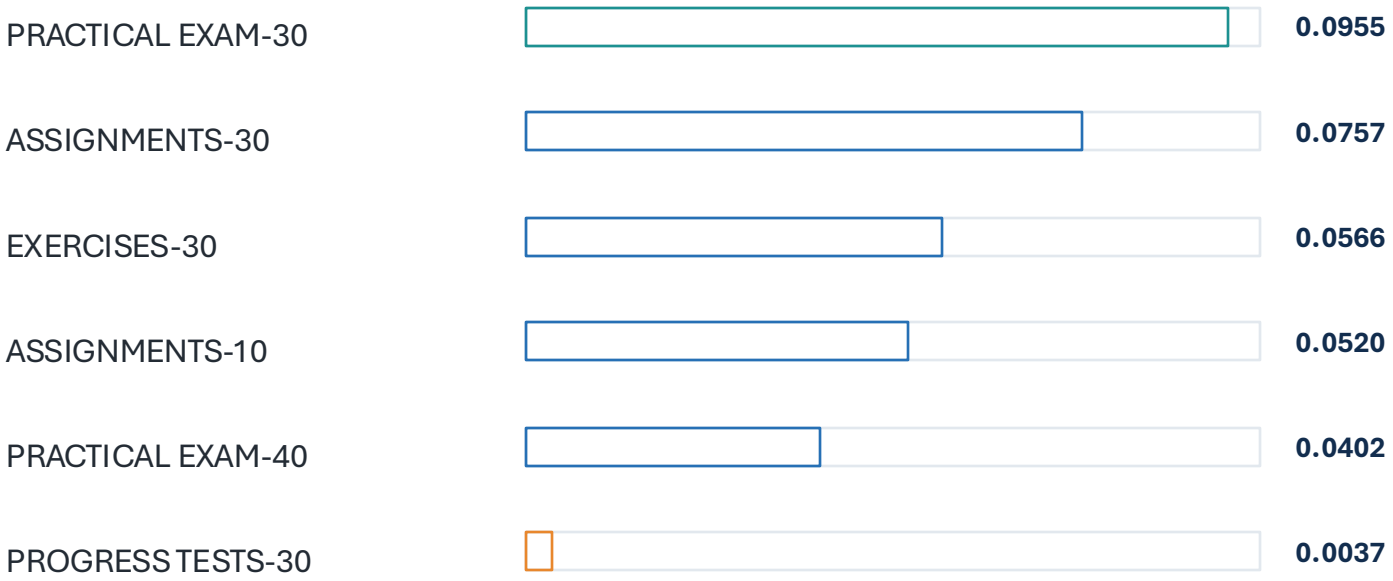
F2 chỉ tăng rất nhỏ; sự thay đổi chính nằm ở operating point: precision cao hơn, recall thấp hơn.

Kết luận phù hợp:

“Evidence does not establish a material improvement.”

RQ6 — Corect SHAP

Mean absolute SHAP



Sửa số liệu

Dùng dữ liệu từ file grouper.zip thay cho file .tex cũ
PRACTICAL EXAM-30: 0.095475 thay cho 0.151325;
PROGRESS TESTS-30: 0.003660 thay cho 0.

SHAP giải thích model behavior; không phải causal mechanism.

Không được lấy SHAP cũ từ production/development run để thay cho grouped RQ6.

Hai phép đo khác nhau: correlation không mâu thuẫn với SHAP

Pooled correlation

PROGRESS TESTS-30
r = −0.8239; n = 165

≠

Model contribution

PROGRESS TESTS-30
mean |SHAP| = 0.003660

RQ1

RQ6

- Correlation: how strongly the feature is associated with TARGET among rows where it is observed
- SHAP: how much the feature contributes to predictions of the trained multivariate model
- Population, dependence, model behavior và sampling có thể khác nhau.

Hai thí nghiệm và hai quần thể: phải ghi nhãn trước khi so sánh

Production split

Test rows

22,141

random 60/20/20

Overlap

22.08%

≈4,888 test rows

Có thể lạc quan vì group overlap với train.

Grouped split

Test rows

21,977

grouped split

Overlap

0

(SOURCE_FILE, CODE)

Đây là ước lượng robustness mạnh hơn, nhưng chưa phải prospective generalization.

Population count

124,791 cleaned	110,704 modeling	100,603 HAS_PREFINAL_EXCL_PE

110,704 là modeling population của grouped pipeline; 100,603 không được tự động coi là cùng quần thể.

Cơ sở phương pháp: hợp lý, nhưng phạm vi kết luận phải có giới hạn

RQ1 / RQ4

Point-biserial/Pearson cho association; within-file correlation + aggregation cho consistency.

RQ2 / RQ5

Năm tree-based classifiers; grouped split trực tiếp xử lý overlap theo (SOURCE_FILE, CODE).

RQ3 / RQ6

Training-only SMOTE, validation-only threshold, untouched test; SHAP giải thích model.

Configured models

Decision Tree: balanced
Random Forest: 300 trees, balanced
XGBoost: 300, lr=0.05, depth=6
LightGBM: 300, lr=0.05
CatBoost: 300, lr=0.05, depth=6

Giới hạn chung

- No cross-validation.
- No hyperparameter tuning.
- Class weighting không đồng nhất giữa models.
- SHAP additivity chưa được independent validation.
- Chưa có retraining/audit dữ liệu độc lập.

Bottom line — claim nào có thể mang vào phần kết luận

1 · Signal

Pre-final scores có liên hệ âm mạnh với unsuccessful outcomes.

2 · Replication

Practical Exam là family được lặp lại tốt nhất theo ≥5 files.

3 · Model

RF mạnh nhất theo validation F2; superiority phụ thuộc metric.

4 · Leakage

Production split có overlap; grouped split đáng tin cậy hơn cho robustness.

5 · SMOTE

Operating point đổi, F2 chỉ đổi rất nhỏ.

6 · Explain

PRACTICAL EXAM-30 đứng đầu grouped SHAP.

Sửa kết luận cũ và giữ đúng nguồn số liệu

Không dùng	Dùng
SHAP Practical Exam-30 ≈ 0.151325	**0.095475**
Progress Tests-30 SHAP = 0	**0.003660**
Additivity checked and failed	**Not measured**
Random Forest best overall	**Best under validation F2**

Nguồn ưu tiên

- RQ1–RQ3: existing .tex + corrections in handoff.
- RQ4–RQ6: grouped ZIP; ưu tiên run_metadata → FINAL_NEW_RQ_SUMMARY → CSV.
- RQ6 SHAP: RQ3_SHAP_global_importance.csv + SHAP_metadata.json.